

АБ-тестирование

Подготовка и проведение



ТИНЬКОФФ



Для чего нужны АБ тесты?



ТИНЬКОФФ

Зачем нужны A/B-тесты

- Продукт: Тинькофф Квест
- Проблема: в ночное время низкая посещаемость квестов
- Гипотеза: скидка 20% на ночную цену повысит заполненность

Вопрос: как понять, что всё работает?

Зачем нужны А/В-тесты

- Продукт: Тинькофф Квест
- Проблема: в ночное время низкая посещаемость квестов
- Гипотеза: скидка 20% на ночную цену повысит заполненность

Вопрос: как понять, что всё сработает?

Давайте позвоним клиентам и опросим их!

- Провели опрос и 80% клиентов сказали, что скидка привлекательна и они придут.
- На деле – ситуация осталась прежней. Причем мы дали скидку тем, кто бы и так пришел (так как обзвон клиентов не повлиял на приток клиентов).
- Что в итоге плохо: потратили ресурсы на обзвон клиентов и продали слишком дешевые квесты (не забываем про скидку 20%)

Зачем нужны А/В-тесты

- Продукт: Тинькофф Квест
- Проблема: в ночное время низкая посещаемость квестов
- Гипотеза: скидка 20% на ночную цену повысит заполненность

Вопрос: как понять, что всё сработает?

Давайте позвоним клиентам и опросим их!

- Провели опрос и 80% клиентов сказали, что скидка привлекательна и они придут.
- На деле – ситуация осталась прежней. Причем мы дали скидку тем, кто бы и так пришел (так как обзвон клиентов не повлиял на приток клиентов).
- Что в итоге плохо: потратили ресурсы на обзвон клиентов и продали слишком дешевые квесты (не забываем про скидку 20%)

Мы потеряли деньги =(
Как понять, в чем проблема?

Что такое АБ тест?



ТИНЬКОФФ

A/B-тесты: принцип проведения

У вас есть база клиентов, состоящая из X человек.

Вы хотите сделать какое-то изменение вашего продукта.

А/В-тесты: принцип проведения

У вас есть база клиентов, состоящая из X человек.

Вы хотите сделать какое-то изменение вашего продукта.

Чтобы понять, даст ли ваше изменение нужный эффект делается следующее:

1. Случайным образом делим базу клиентов на 2 однородные группы: А (control) и В (test)
2. Для группы В применяем изменение, для А оставляем все как есть.
3. Ждем (мониторим корректность процессов).
4. Сравниваем поведение и различные показатели этих групп.
5. Выносим вердикт: какой из вариантов победил.

Как решить проблему с квестами?




Зачем нужны A/B-тесты

Решение: A/B – тест

- Чтобы максимально приблизиться к реальным условиям – возьмем малую выборку клиентов и предложим скидку только им. А другим клиентам оставим все как было.
- В дальнейшем посмотрим – стали ли клиенты со скидкой лучше заказывать ночные квесты по сравнению с другой группой.
- Если ничего не изменится, то много денег мы не потеряем, так как запустились только на части клиентов.

A/B-тесты: принцип проведения на примере квестов



Подготовка к тесту



С чего начать?

Проблема и гипотеза (как решить проблему?)

Вы должны чётко понимать:

- Где у вашего продукта слабое место? (Проблема)
- Что можно сделать, чтоб это исправить? (Гипотеза)
- Какая будет стратегия? (Проверка гипотезы)
- Какие у вас будут метрики?

С чего начать?

Проблема и гипотеза (как решить проблему?)

Вы должны чётко понимать:

- Где у вашего продукта слабое место? (Проблема) => низкая посещаемость в ночное время
- Что можно сделать, чтоб это исправить? (Гипотеза)
- Какая будет стратегия? (Проверка гипотезы)
- Какие у вас будут метрики?

С чего начать?

Проблема и гипотеза (как решить проблему?)

Вы должны чётко понимать:

- Где у вашего продукта слабое место? (Проблема) => низкая посещаемость в ночное время
- Что можно сделать, чтоб это исправить? (Гипотеза) => скидка 20% на ночное время увеличит востребованность
- Какая будет стратегия? (Проверка гипотезы)
- Какие у вас будут метрики?

С чего начать?

Проблема и гипотеза (как решить проблему?)

Вы должны чётко понимать:

- Где у вашего продукта слабое место? (Проблема) => низкая посещаемость в ночное время
- Что можно сделать, чтоб это исправить? (Гипотеза) => скидка 20% на ночное время увеличит востребованность
- Какая будет стратегия? (Проверка гипотезы) => при посещении ночью части клиентов будем давать скидку
- Какие у вас будут метрики?

С чего начать?

Проблема и гипотеза (как решить проблему?)

Вы должны чётко понимать:

- Где у вашего продукта слабое место? (Проблема) => низкая посещаемость в ночное время
- Что можно сделать, чтоб это исправить? (Гипотеза) => скидка 20% на ночное время увеличит востребованность
- Какая будет стратегия? (Проверка гипотезы) => при посещении ночью части клиентов будем давать скидку
- Какие у вас будут метрики?

Какие метрики нужны?



Какие метрики нужны?

- После выбора бизнес гипотезы необходимо понять как измерить то, что вам нужно. Выбираем ключевую метрику, метрика, на основе которой будем принимать решение => **конверсия в покупку квеста в ночное время**

А достаточно ли одной метрики?

Какие метрики нужны?

- После выбора бизнес гипотезы необходимо понять как измерить то, что вам нужно. Выбираем ключевую метрику, метрика, на основе которой будем принимать решение => **конверсия в покупку квеста в ночное время**

А достаточно ли одной метрики?

- Нужно понимать, что даже если нужная метрика выросла, какая-то другая важная метрика могла упасть

Какие метрики бывают?



ТИНЬКОФФ

Типы метрик

Метрики можно поделить на три основных типа

- Целевая
- **guardrail** (барьерная/контрольная)
- **прокси** (опережающая)

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста
- **guardrail** (барьерная/контрольная)
- **прокси** (опережающая)

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять
- **прокси** (опережающая)

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять
- **прокси** (опережающая) – метрики, на обнаружения изменений которых нужно меньше времени, более чувствительная метрика, к примеру с меньшей дисперсией

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять
- **прокси** (опережающая) – метрики, на обнаружения изменений которых нужно меньше времени, более чувствительная метрика, к примеру с меньшей дисперсией, ВАЖНО: прокси метрика и целевая метрика должна быть направлены одинаково

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста (к примеру, конверсия в покупку)
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять
- **прокси** (опережающая) – метрики, на обнаружения изменений которых нужно меньше времени, более чувствительная метрика, к примеру с меньшей дисперсией, ВАЖНО: прокси метрика и целевая метрика должна быть направлены одинаково.

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста (к примеру, конверсия в покупку)
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять (к примеру, конверсия в следующую покупку)
- **прокси** (опережающая) – метрики, на обнаружения изменений которых нужно меньше времени, более чувствительная метрика, к примеру с меньшей дисперсией, ВАЖНО: прокси метрика и целевая метрика должна быть направлены одинаково.

Типы метрик

Метрики можно поделить на три основных типа

- **Целевая** – на основе этой метрики принимаем решение об успешности теста (к примеру, конверсия в покупку)
- **guardrail** (барьерная/контрольная) – метрика, которую нельзя ронять (к примеру, конверсия в следующую покупку)
- **прокси** (опережающая) – метрики, на обнаружения изменений которых нужно меньше времени, более чувствительная метрика, к примеру с меньшей дисперсией, ВАЖНО: прокси метрика и целевая метрика должна быть направлены одинаково.

Чтобы точнее понять суть прокси метрики, дадим отдельный пример выбора прокси метрики

Пример прокси метрики

Рассматриваем поиск Яндекса

Пусть мы выбрали ключевую метрику – количество кликов на клиента

Рассмотрим прокси метрику – количество сессий на клиента

Пример прокси метрики

Яндекс

морепфото

Найти

поисккартинкивидеокартымаркетновостипереводчикеще

Фото моря - 70 красивых фото моря и океана - фото...

mementovitae.ru > sea-photo

Фото моря. Море... Волшебная, манящая стихия, которая ассоциируется с отдыхом, релаксом и путешествиями.

Нашлось 62 млн результатов
148 тыс. показов в месяц
Дать объявление

more фото — смотрите картинки

yandex.ru/images > морепфото



Картинки красивые море (36 фото) • Прикольные картинки...

BipBar.ru > krasivye-kartinki...more-36-foto.html

Большинство людей хотят отдохнуть на море. Так можно расслабиться и отдохнуть на белоснежных пляжах под теплыми солнечными лучами.

More (46 фото)

ClassPic.ru > blog/more-46-foto.html

Море (46 фото). вода • море • природа. Море — это дорога, ведущая в неведомые дали, дорога, которая без конца и без времени.

Галерея фотографий "Море фото". Красивые фотографии...

svistanet.com > fotografiya/krasivye-foto-more.html

Красивые фото Море. Галерея красивых фотографий моря. Море влечет не только, как место отдыха. И не исключительно потому, что море...

Красивые фото моря и океана | Как правильно

kakpravilino.com > krasivye-foto-morya-i-okeana/

Красивые фото моря и океана. Глядя на море и океан человек невольно начинает задумываться о высоком и вечном.

Яндекс

морепфото

Найти

поисккартинкивидеокартымаркетновостипереводчикеще

Фото моря - 70 красивых фото моря и океана - фото...

mementovitae.ru > sea-photo

Фото моря. Море... Волшебная, манящая стихия, которая ассоциируется с отдыхом, релаксом и путешествиями.

Нашлось 62 млн результатов
148 тыс. показов в месяц
Дать объявление

more фото — смотрите картинки

yandex.ru/images > морепфото



Картинки красивые море (36 фото) • Прикольные картинки...

BipBar.ru > krasivye-kartinki...more-36-foto.html

Большинство людей хотят отдохнуть на море. Так можно расслабиться и отдохнуть на белоснежных пляжах под теплыми солнечными лучами.

More (46 фото)

ClassPic.ru > blog/more-46-foto.html

Море (46 фото). вода • море • природа. Море — это дорога, ведущая в неведомые дали, дорога, которая без конца и без времени.

Галерея фотографий "Море фото". Красивые фотографии...

svistanet.com > fotografiya/krasivye-foto-more.html


Красивые фото Море. Галерея красивых фотографий моря. Море влечет не только, как место отдыха. И не исключительно потому, что море...

Красивые фото моря и океана | Как правильно

kakpravilino.com > krasivye-foto-morya-i-okeana/

Красивые фото моря и океана. Глядя на море и океан человек невольно начинает задумываться о высоком и вечном.


Пример прокси метрики




В данном случае:
количество кликов увеличилось и увеличилось
количество сессий

Количество сессий будет прокси метрикой для
целевой метрики для данного теста

Пример прокси метрики



Пример прокси метрики



В данном случае:
количество кликов увеличилось и уменьшилось
количество сессий так как не был получен ответ
сразу и мог пойти в другое место, где ответ будет
сразу

Количество сессий будет уже не будет прокси
метрикой для целевой метрики для данного теста

А нужен ли АБ?



Задавай себе эти вопросы

- У нас есть гипотеза?
- Достаточно ли нам клиентов и стабильны ли конверсии?
Если на наш сайт заходит 50 клиентов в месяц, то смысла в тестировании нет.
- Готовы ли мы технически реализовать новый функционал?
- Может быть хватит теста «на пальцах»?
- Если доработки для полноценного построения нового процесса слишком сложные и дорогие, то можно попробовать обойтись без них: опрос или тест с ограниченным функционалом

Что еще можно сделать перед
запуском?



Что сделать перед запуском

- Ведите дневник теста
Записывайте что и как посчитали, все идеи и результаты аналитики, сохраняйте ВЫБОРКИ.

Что сделать перед запуском

- Ведите дневник теста

Записывайте что и как посчитали, все идеи и результаты аналитики, сохраняйте ВЫБОРКИ.

- Проводите A/A-тест

Иногда полезно непосредственно перед запуском на обе группы запустить старую версию процесса. Тем самым вы сможете убедиться, что вы честно поделили выборку, или же обнаружить свою ошибку.

Есть вариант A/A/B – теста.

Что сделать перед запуском

- Ведите дневник теста
Записывайте что и как посчитали, все идеи и результаты аналитики, сохраняйте ВЫБОРКИ.
- Проводите A/A-тест
Иногда полезно непосредственно перед запуском на обе группы запустить старую версию процесса. Тем самым вы сможете убедиться, что вы честно поделили выборку, или же обнаружить свою ошибку.
Есть вариант A/A/B – теста.
- Настроить онлайн отчет по всем показателям
Если вдруг что-то пойдет не так, вы сможете оперативно это обнаружить.

Что сделать перед запуском

- Ведите дневник теста
Записывайте что и как посчитали, все идеи и результаты аналитики, сохраняйте ВЫБОРКИ.
- Проводите A/A-тест
Иногда полезно непосредственно перед запуском на обе группы запустить старую версию процесса. Тем самым вы сможете убедиться, что вы честно поделили выборку, или же обнаружить свою ошибку.
Есть вариант A/A/B – теста.
- Настроить онлайн отчет по всем показателям
Если вдруг что-то пойдет не так, вы сможете оперативно это обнаружить.
- Будьте готовы к БАГАМ и СБОЯМ

Что нужно понять перед запуском?


На ком тестируем? Кто является нашим таргетом?

Что нужно понять перед запуском?

На ком тестируем? Кто является нашим таргетом?

Когда пользователи становятся частью эксперимента?

Делим на тест/контроль в самом начале воронки или когда они дошли до этапа с изменением.



Требования к выборке



Требования к выборке

- Первым делом необходимо понять, кто является нашей целевой аудиторией – это будет наша генеральная совокупность

Требования к выборке

- Первым делом необходимо понять, кто является нашей целевой аудиторией – это будет наша генеральная совокупность
- Из всей генсовокупности мы выбираем небольшую часть – выборка нашего теста

Требования к выборке

- Первым делом необходимо понять, кто является нашей целевой аудиторией – это будет наша генеральная совокупность
- Из всей генсовокупности мы выбираем небольшую часть – выборка нашего теста
- Почему не запускаем сразу на всей аудитории?

Требования к выборке

- Первым делом необходимо понять, кто является нашей целевой аудиторией – это будет наша генеральная совокупность
- Из всей генсовокупности мы выбираем небольшую часть – выборка нашего теста
- Почему не запускаем сразу на всей аудитории? Прежде чем запускать на всех, нужно убедиться в том, что мы получим необходимый эффект при меньших костях, и только потом, когда мы уверены, что эффект будет, масштабируем на всю аудиторию

Требования к выборке

- Первым делом необходимо понять, кто является нашей целевой аудиторией – это будет наша генеральная совокупность
- Из всей генсовкупности мы выбираем небольшую часть – выборка нашего теста
- Почему не запускаем сразу на всей аудитории? Прежде чем запускать на всех, нужно убедиться в том, что мы получим необходимый эффект при меньших costs, и только потом, когда мы уверены, что эффект будет, масштабируем на всю аудиторию
- Поэтому отсюда накладываются некоторые условия на выборку

Репрезентативность

От выборки требуем **репрезентативность**:

- Выборка должна отражать свойства генеральной совокупности



Репрезентативность

От выборки требуем **репрезентативность**:

- Выборка должна отражать свойства генеральной совокупности
- При любой сегментации выборки, ее распределение по сегментам должно быть похоже на распределение генеральной совокупности



Репрезентативность

От выборки требуем **репрезентативность**:

- Выборка должна отражать свойства генеральной совокупности
- При любой сегментации выборки, ее распределение по сегментам должно быть похоже на распределение генеральной совокупности
- Как можно проверить?



Репрезентативность

От выборки требуем **репрезентативность**:

- Выборка должна отражать свойства генеральной совокупности
- При любой сегментации выборки, ее распределение по сегментам должно быть похоже на распределение генеральной совокупности
- Как можно проверить?
- Проверить можно с помощью расстояния Кульбака-Лейблера (Stability index)



Stability index



Требования к выборке. Stability index

Расстояние Кульбака-Лейблера (Stability index):

Вероятность, с которой признак X принимает значения x_i для $i = 1, \dots, k$ в выборках A и B , обозначим:

$$P(X = x_i | A) = p_{Ai}$$

$$P(X = x_i | B) = p_{Bi}$$

Требования к выборке. Stability index

Расстояние Кульбака-Лейблера (Stability index):

Вероятность, с которой признак X принимает значения x_i для $i = 1, \dots, k$ в выборках A и B , обозначим:

$$P(X = x_i | A) = p_{Ai}$$

$$P(X = x_i | B) = p_{Bi}$$

Пусть все $p_{Ai} > 0$ и $p_{Bi} > 0$.

$$SI = \sum (p_{Ai} - p_{Bi}) * (\ln(p_{Ai}) - \ln(p_{Bi}))$$

Требования к выборке. Stability index

Расстояние Кульбака-Лейблера (Stability index):

Вероятность, с которой признак X принимает значения x_i для $i = 1, \dots, k$ в выборках A и B , обозначим:

$$P(X = x_i | A) = p_{Ai}$$

$$P(X = x_i | B) = p_{Bi}$$

Пусть все $p_{Ai} > 0$ и $p_{Bi} > 0$.

$$SI = \sum (p_{Ai} - p_{Bi}) * (\ln(p_{Ai}) - \ln(p_{Bi}))$$

Что будет нормой?

Требования к выборке. Stability index

Расстояние Кульбака-Лейблера (Stability index):

Вероятность, с которой признак X принимает значения x_i для $i = 1, \dots, k$ в выборках A и B , обозначим:

$$P(X = x_i | A) = p_{Ai}$$

$$P(X = x_i | B) = p_{Bi}$$

Пусть все $p_{Ai} > 0$ и $p_{Bi} > 0$.

$$SI = \sum (p_{Ai} - p_{Bi}) * (\ln(p_{Ai}) - \ln(p_{Bi}))$$

Что будет нормой?

$SI < 0.1$ - отсутствие значимого изменения.

$SI \geq 0.1$ и < 0.2 о незначительном изменении, которые необходимо исследовать.

$SI \geq 0.2$ – существенное смещение, необходимы изменения, в идеале не использовать выборку.

Сплитование



ТИНЬКОФФ

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Чем такой вариант плох?

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Чем такой вариант плох? Многие функции рандома при повторном запуске могут сгенерить разные значения для одного элемента

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Чем такой вариант плох? Многие функции рандома при повторном запуске могут сгенерить разные значения для одного элемента

- Используем хэш функцию от уникального ключа элемента (ключ клиента, ключ счета и тд)

Чем такой вариант плох?

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Чем такой вариант плох? Многие функции рандома при повторном запуске могут сгенерить разные значения для одного элемента

- Используем хэш функцию от уникального ключа элемента (ключ клиента, ключ счета и тд)

Чем такой вариант плох? Если есть два одновременных теста, то они будут влиять друг на друга

Сплитование

Способы деления на две группы:

- Для каждого элемента в выборке генерируем два псевдорандомных числа 1 и 0 с вероятностями p и $1-p$. В контроль добавляем элементы со значением 0, в тест – со значениями 1.

Чем такой вариант плох? Многие функции рандома при повторном запуске могут сгенерить разные значения для одного элемента

- Используем хэш функцию от уникального ключа элемента (ключ клиента, ключ счета и тд)

Чем такой вариант плох? Если есть два одновременных теста, то они будут влиять друг на друга

- Хэш с «солью»: добавляем к ключу клиента уникальную для теста приставку/суффикс

Требования к группам



Требования к группам

После того, как мы получили две группы тест и контроль, необходимо проверить, что эти две группы:

- 1) Имеют достаточное количество элементов, чтобы мы смогли задетектить статзначимый аплифт (об этом подробнее далее)

Требования к группам

После того, как мы получили две группы тест и контроль, необходимо проверить, что эти две группы:

- 1) Имеют достаточное количество элементов, чтобы мы смогли задетектить статзначимый аплифт (об этом подробнее далее)
- 2) Достаточно «одинаковы», чтобы мы могли предположить, что единственное чем отличаются выборки, это наличие влияния нашего теста, так называемая гомогенность групп (однородности)

Гомогенность



Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колгоморова-Смирнова

Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колgomорова-Смирнова
- Однако, на прошлой лекции было показано, что этот критерий на самом деле работает уступает другим критериям

Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колгоморова-Смирнова
- Однако, на прошлой лекции было показано, что этот критерий на практике уступает другим критериям
 - В одномерном случае это Anderson
 - MMD во многомерном случае

Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колгоморова-Смирнова
- Однако, на прошлой лекции было показано, что этот критерий на практике уступает другим критериям
 - В одномерном случае это Anderson
 - MMD во многомерном случае
- Общий подход к проверке гомогенности заключается в том, что мы проверяем распределение какой-то метрики в тесте и в контроле и сравниваем их распределение при помощи ряда критериев
- В том числе можно выбрать метрику, которая хорошо коррелирует с целевой метрикой (средняя длина сессии и количество сессий на клиента, к примеру)

Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колгоморова-Смирнова
- Однако, на прошлой лекции было показано, что этот критерий на практике уступает другим критериям
 - В одномерном случае это Anderson
 - MMD во многомерном случае
- Общий подход к проверке гомогенности заключается в том, что мы проверяем распределение какой-то метрики в тесте и в контроле и сравниваем их распределение при помощи ряда критериев
- В том числе можно выбрать метрику, которая хорошо коррелирует с целевой метрикой (средняя длина сессии и количество сессий на клиента, к примеру)
- Для этого можем проверить корреляцию двух метрик стандартными способами

Критерии проверки однородности

- Критерий, о котором знают многие, это критерий Колgomорова-Смирнова
- Однако, на прошлой лекции было показано, что этот критерий на практике уступает другим критериям
 - В одномерном случае это Anderson
 - MMD во многомерном случае
- Общий подход к проверке гомогенности заключается в том, что мы проверяем распределение какой-то метрики в тесте и в контроле и сравниваем их распределение при помощи ряда критериев
- В том числе можно выбрать метрику, которая хорошо коррелирует с целевой метрикой (средняя длина сессии и количество сессий на клиента, к примеру)
- Для этого можем проверить корреляцию двух метрик стандартными способами
- **Вариант со звездочкой***: брать не по каждому отдельному признаку, а рассматривать юзера как вектор из значений и переходить к многомерному анализу, обобщать критерии, да и задача координально меняется

Признаки однородности



Критерии проверки однородности

- Признаки, которые зачастую берут для проверки однородности
 - Соцдем (гео, возраст, пол, брачный статус и тд)

Критерии проверки однородности

- Признаки, которые зачастую берут для проверки однородности
 - Соцдем (гео, возраст, пол, брачный статус и тд)
 - Активность в веб версии/в мобильной версии (количество сессий, глубина сессии, время сессии и тд)

Критерии проверки однородности

- Признаки, которые зачастую берут для проверки однородности
 - Соцдем (гео, возраст, пол, брачный статус и тд)
 - Активность в веб версии/в мобильной версии (количество сессий, глубина сессии, время сессии и тд)
 - Финансовая активность (остаток на счете, баланс покупок, баланс переводов, количество продуктов и тд)

Критерии проверки однородности

- Признаки, которые зачастую берут для проверки однородности
 - Соцдем (гео, возраст, пол, брачный статус и тд)
 - Активность в веб версии/в мобильной версии (количество сессий, глубина сессии, время сессии и тд)
 - Финансовая активность (остаток на счете, баланс покупок, баланс переводов, количество продуктов и тд)
 - Активность в самом продукте (частота использования, глубина использования и тд)

Критерии проверки однородности

- Признаки, которые зачастую берут для проверки однородности
 - Соцдем (гео, возраст, пол, брачный статус и тд)
 - Активность в веб версии/в мобильной версии (количество сессий, глубина сессии, время сессии и тд)
 - Финансовая активность (остаток на счете, баланс покупок, баланс переводов, количество продуктов и тд)
 - Активность в самом продукте (частота использования, глубина использования и тд)
 - Участие в других тестах (при наличии крутой АБ платформы)

Формулировка гипотезы




Постановка гипотезы

Вспомним теорию с прошлой лекции:

- У нас есть H_0 гипотеза, которую мы хотим отклонить, есть H_1 гипотеза – альтернатива для H_0
- В рамках АБ теста, мы предполагаем в H_0 , что изменения не будет
- В зависимости от наших ожидания, у нас есть три варианта альтернативной гипотезы
 1. правосторонняя альтернатива
 2. левосторонняя альтернатива
 3. двухсторонняя альтернатива
- На прошлой лекции был упомянут алгоритм выбора критерия, придерживаемся его

Постановка гипотезы



Ошибки 1 и 2 рода



Постановка гипотезы

- Напомним про ошибки первого и второго рода

	Null Hypothesis is TRUE	Null Hypothesis is FALSE
Reject null hypothesis	 Type I Error (False positive)	 Correct Outcome! (True positive)
Fail to reject null hypothesis	 Correct Outcome! (True negative)	 Type II Error (False negative)

Постановка гипотезы

- Напомним про ошибки первого и второго рода
- Ошибка I рода жестко ограничивается. Она критичнее ошибки II рода (α)

	Null Hypothesis is TRUE	Null Hypothesis is FALSE
Reject null hypothesis	 Type I Error (False positive)	 Correct Outcome! (True positive)
Fail to reject null hypothesis	 Correct Outcome! (True negative)	 Type II Error (False negative)

Постановка гипотезы


- Напомним про ошибки первого и второго рода
- Ошибка I рода жестко ограничивается. Она критичнее ошибки II рода (α)
- Ошибка II рода минимизируется (β)
- Мощность критерия ($1 - \beta$) - это способность критерия выявлять различия, если они есть

	Null Hypothesis is TRUE	Null Hypothesis is FALSE
Reject null hypothesis	 Type I Error (False positive)	 Correct Outcome! (True positive)
Fail to reject null hypothesis	 Correct Outcome! (True negative)	 Type II Error (False negative)

Постановка гипотезы

- Напомним про ошибки первого и второго рода
- Ошибка I рода жестко ограничивается. Она критичнее ошибки II рода ($\leq \alpha$)
- Ошибка II рода минимизируется (β)
- Мощность критерия ($1 - \beta$) - это способность критерия выявлять различия, если они есть

	Null Hypothesis is TRUE	Null Hypothesis is FALSE
Reject null hypothesis	 Type I Error (False positive)	 Correct Outcome! (True positive)
Fail to reject null hypothesis	 Correct Outcome! (True negative)	 Type II Error (False negative)



Постановка гипотезы



Постановка гипотезы

		Верна ли H_0 (новая фича не увеличила конверсию)?	
		Верна	Не верна
Принимаем ли мы H_0 (мы не заметили увеличения конверсии в тесте)?	Принимается	Тест не выиграл	Мы упустили победу теста
	Отвергается	Разницы на самом деле нет, но мы все равно решили, что победил тест	Тест выиграл

Алгоритм



ТИНЬКОФФ

Базовые шаги

В итоге получаем следующий алгоритм:

1. Выбираем стат критерий в зависимости от наших данных и нашей метрики

Базовые шаги

В итоге получаем следующий алгоритм:

1. Выбираем стат критерий в зависимости от наших данных и нашей метрики
2. Ставим H_0 и H_1

Базовые шаги

В итоге получаем следующий алгоритм:

1. Выбираем стат критерий в зависимости от наших данных и нашей метрики
2. Ставим H_0 и H_1
3. Задаем α и β (влияет на длительность теста и размеры выборок, обсудим дальше)

Базовые шаги

В итоге получаем следующий алгоритм:

1. Выбираем стат критерий в зависимости от наших данных и нашей метрики
2. Ставим H_0 и H_1
3. Задаем α и β (влияет на длительность теста и размеры выборок, обсудим дальше)
4. Для выбранного критерия считаем статистику

Базовые шаги

В итоге получаем следующий алгоритм:

1. Выбираем стат критерий в зависимости от наших данных и нашей метрики
2. Ставим H_0 и H_1
3. Задаем α и β (влияет на длительность теста и размеры выборок, обсудим дальше)
4. Для выбранного критерия считаем статистику
5. Если по завершению теста получаем, что $pvalue \leq \alpha$, то отклоняем H_0 в пользу H_1 и считаем, что мы получили статзначимый аплифт, в противном случае не отклоняем H_0 и говорим, что получили нестатзначимый аплифт

Вспомним про квесты

Целевая метрика: посещение квеста в ночное время

Для каждого клиента сопоставляем 1 если посетил, 0 если посетил. Получаем распределение Бернулли

Выборка X_1 – с распределением Бернулли p_1 (тест), выборка X_2 – с распределением Бернулли p_2 (контроль)

Как вариант, выбираем Z-тест Фишера

$H_0: p_1 = p_2$, $H_1: p_1 \geq p_2$

Ограничиваем ошибку 1 рода $\alpha \leq 0.05$

Считаем Z статистику, получаем pvalue и сравниваем с 0.05

Принимаем решение: отклоняем или не отклоняем H_0

Основные двухвыборочные критерии



Z-критерий Фишера для двух долей

Выборки: $X_{11}, \dots, X_{1n}$; X_1 - Бернулли p_1

$X_{21}, \dots, X_{2k}$; X_2 - Бернулли p_2

Нулевая гипотеза $H_0: p_1 = p_2$

Альтернативная гипотеза $H_1: p_1 (!=, <, >) p_2$

Статистика: $T(X_1, X_n) = \frac{\widehat{p}_1 - \widehat{p}_2}{\sqrt{P(1-P)(1/n_1 + 1/n_2)}}$,

где $P = \frac{\widehat{p}_1 n_1 + \widehat{p}_2 n_2}{n_1 + n_2}$

Т-критерий оценки Стьюдента (двухвыборочный)

Выборки: $X_{11}, \dots, X_{1n}$ нормально распределенная с (m_0, σ_0^2)

$X_{21}, \dots, X_{2k}$ нормально распределенная с (m_1, σ_1^2) ;

Нулевая гипотеза $H_0 : m_1 = m_2$

Альтернативная гипотеза $H_1 : m_1 \neq m_2$

Статистика: $T(X) = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{k}}}$

В случае равенства дисперсий $\sigma_1 = \sigma_2 = \sigma$: $T(X) = \frac{\bar{X}_1 - \bar{X}_2}{\sigma \sqrt{\frac{1}{n} + \frac{1}{k}}}$

Вариант для сравнения прибыли – U-критерий Манна-Уитни

Работает, если мы сравниваем медианы в двух группах. Например, для доходности.

Как применять:

- Есть две выборки из n_1 и n_2 элементов, каждому наблюдению соответствует количественная величина. Запоминаем, из какой выборки каждое наблюдение.
- Объединяем две выборки и ранжируем их (если есть одинаковые элементы, то их ранг - среднее). Получится $n_1 + n_2$ рангов.
- Разделяем обратно ряд на исходные выборки, но теперь они ранжированы. Считаем суммы рангов R_1 и R_2
- Вычисляем:

$$U_1 = n_1 * n_2 + \frac{n_1 * (n_1 + 1)}{2} - R_1$$

$$U_2 = n_1 * n_2 + \frac{n_2 * (n_2 + 1)}{2} - R_2$$

Вариант для сравнения прибыли – U-критерий Манна-Уитни

- Получаем значение критерия:

$$U = \min(U_1, U_2)$$

- Проверяем критическое значение критерия для n_1 и n_2

Для больших выборок p-value можно определить по следующей формуле:

$$p = \frac{|U - n_1 n_2 / 2|}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

Вариант для сравнения прибыли – U-критерий Манна-Уитни

- Получаем значение критерия:

$$U = \min(U_1, U_2)$$

- Проверяем критическое значение критерия для n_1 и n_2

Для больших выборок p-value можно определить по следующей формуле:

$$p = \frac{|U - n_1 n_2 / 2|}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

Применимость критерия:

- В каждой из выборок должно быть не менее 3 значений признака. Допускается, чтобы в одной выборке было два значения, но во второй тогда не менее пяти.
- В выборочных данных не должно быть совпадающих значений (все числа — разные) или таких совпадений должно быть очень мало (до 10)

Проверка на нормальность

В прошлой лекции вам рассказали, что на практике нормальность метрик применять не нужно


Проверка на нормальность

В прошлой лекции вам рассказали, что на практике нормальность метрик применять не нужно

НО про конечность матожидания и дисперсии нужно помнить для ЦПТ

Выбор критерия

A Classification of Hypothesis Testing Procedures for Examining Differences



Расчет размера групп



Размер выборки

- От чего зависит размер выборки?
- Сам критерий фиксирует ошибку первого рода, и никак не учитывает ошибку второго рода
- Однако, ошибка второго рода уменьшается с ростом размера выборка для фиксированного отклонения
- Таким образом мы можем регулировать «минимальный» размер выборки при помощи мощности критерия

MDE



ТИНЬКОФФ

MDE

MDE - это наименьший истинный эффект полученный от изменений, который имеет определенный уровень статистической мощности для определенного уровня статистической значимости, учитывая конкретный статистический тест.

Чем меньше MDE, тем лучше для нас




График 1: по вертикали — Мощность, по горизонтали — Объем выборки (N), α — ошибка I рода. В скобках условные обозначения силы эффекта

MDE

Введем следующие обозначения

$$\text{Lift} = \frac{\bar{Y}_t - \bar{Y}_c}{\bar{Y}_c}, \text{ где } \bar{Y}_t, \bar{Y}_c - \text{средние метрики теста и контроля}$$

MDE

Введем следующие обозначения

$\text{Lift} = \frac{\bar{Y}_t - \bar{Y}_c}{\bar{Y}_c}$, где $\bar{Y}_t, \bar{Y}_c$ – средние метрики теста и контроля

$$\text{Effect Size (cohen's d)} = \frac{\bar{Y}_t - \bar{Y}_c}{SD_{pooled}} = \frac{\bar{Y}_t - \bar{Y}_c}{\sqrt{\frac{(n_t-1)S_t^2 + (n_c-1)S_c^2}{n_t+n_c-2}}}$$

для расчета знаменателя нам требуются либо данные по эксперименту, либо знания о метрике из исторических данных, иначе дисперсию не от куда взять

MDE

Введем следующие обозначения

$\text{Lift} = \frac{\bar{Y}_t - \bar{Y}_c}{\bar{Y}_c}$, где $\bar{Y}_t, \bar{Y}_c$ – средние метрики теста и контроля

$\text{Effect Size (cohen's d)} = \frac{\bar{Y}_t - \bar{Y}_c}{SD_{pooled}} = \frac{\bar{Y}_t - \bar{Y}_c}{\sqrt{\frac{(n_t-1)S_t^2 + (n_c-1)S_c^2}{n_t+n_c-2}}}$

для расчета знаменателя нам требуются либо данные по эксперименту, либо знания о метрике из исторических данных, иначе дисперсию не от куда взять

<i>Effect size</i>	<i>d</i>	Reference
Very small	0.01	[9]
Small	0.20	[8]
Medium	0.50	[8]
Large	0.80	[8]
Very large	1.20	[9]
Huge	2.0	[9]

MDE

Введем следующие обозначения

$\text{Lift} = \frac{\bar{Y}_t - \bar{Y}_c}{\bar{Y}_c}$, где $\bar{Y}_t, \bar{Y}_c$ – средние метрики теста и контроля

$\text{Effect Size (cohen's d)} = \frac{\bar{Y}_t - \bar{Y}_c}{SD_{pooled}} = \frac{\bar{Y}_t - \bar{Y}_c}{\sqrt{\frac{(n_t-1)S_t^2 + (n_c-1)S_c^2}{n_t+n_c-2}}}$ для расчета знаменателя нам требуются либо данные по эксперименту, либо знания о метрике из исторических данных, иначе дисперсию не от куда взять

$\text{Minimum Detectable Effect} = M \frac{S}{\bar{Y}_c}$, где $M = t_{\alpha/2} + t_{\beta}, S = \sqrt{\frac{\sigma_t^2}{n_t} + \frac{\sigma_c^2}{n_c}}$

<i>Effect size</i>	<i>d</i>	Reference
Very small	0.01	[9]
Small	0.20	[8]
Medium	0.50	[8]
Large	0.80	[8]
Very large	1.20	[9]
Huge	2.0	[9]

MDE

Введем следующие обозначения

$Lift = \frac{\bar{Y}_t - \bar{Y}_c}{\bar{Y}_c}$, где $\bar{Y}_t, \bar{Y}_c$ – средние метрики теста и контроля

$Effect\ Size\ (cohen's\ d) = \frac{\bar{Y}_t - \bar{Y}_c}{SD_{pooled}} = \frac{\bar{Y}_t - \bar{Y}_c}{\sqrt{\frac{(n_t-1)S_t^2 + (n_c-1)S_c^2}{n_t+n_c-2}}}$ для расчета знаменателя нам требуются либо данные по эксперименту, либо знания о метрике из исторических данных, иначе дисперсию не от куда взять

$Minimum\ Detectable\ Effect = M \frac{S}{\bar{Y}_c}$, где $M = t_{\alpha/2} + t_{\beta}, S = \sqrt{\frac{\sigma_t^2}{n_t} + \frac{\sigma_c^2}{n_c}}$

<i>Effect size</i>	<i>d</i>	Reference
Very small	0.01	[9]
Small	0.20	[8]
Medium	0.50	[8]
Large	0.80	[8]
Very large	1.20	[9]
Huge	2.0	[9]

В каждом исследовании всегда есть вывод, о том что гипотеза отвергается или принимается. Сравнение P-value с альфой говорит лишь о наличии или отсутствии эффекта, но не говорит о его величине. Ориентируясь на Effect Size, мы также ориентируемся и на мощность. Всегда есть возможность оценить мощность эффекта по ходу или после завершения теста. Это развеет сомнения о его надежности и даст понимание, насколько сильно в эффект можно верить.

Как выбрать длительность теста и размер выборки?

Размер выборки для случая бернулли

$$N = \frac{p(1-p)(z_{1-\alpha} - z_\beta)^2}{k\Delta^2}, \quad M = \frac{p(1-p)(z_{1-\alpha} - z_\beta)^2}{(1-k)\Delta^2}$$

Размер выборки для общего случая

$$N = \frac{\sigma^2(z_{1-\alpha} - z_\beta)^2}{k\Delta^2}, \quad M = \frac{\sigma^2(z_{1-\alpha} - z_\beta)^2}{(1-k)\Delta^2}$$


Где k - доля теста (контроля), Δ - MDE, z_α - квантиль стандартного нормального распределения σ^2 - верхняя оценка дисперсий

P – базовая конверсия

Для двухсторонней альтернативы $z_{1-\alpha} - z_\beta$ заменяем на $z_{1-\alpha/2} - z_\beta$

Описание инструмента – калькулятор АБ-тестов

- Для оценок и принятия решений по АБ-тестам есть уже готовые калькуляторы.
- Один из примеров – <https://abtestguide.com/calc/>



А что дальше? Что стоит за математикой?



Интерпретация результатов

- Допустим мы получили статзначимый аплифт в поставленной нами бизнес гипотезе
- В каких случаях статзначимость не всегда про бизнес?

Интерпретация результатов

- Допустим мы получили статзначимый аплифт в поставленной нами бизнес гипотезе
- Представим ситуацию, что давали кэшбэк на первую покупку 20% и получили результаты полностью удовлетворяющие математику. Но какой здесь есть подвох?

Интерпретация результатов

- Допустим мы получили статзначимый аплифт в поставленной нами бизнес гипотезе
- Представим ситуацию, что давали кэшбэк на первую покупку 20% и получили результаты полностью удовлетворяющие математику. Но какой здесь есть подвох?
- Вспомним, что у нас есть контрольные метрики, которые нам тоже интересны

В данном случае с таким большим процентов кэшбэка мы могли только разово привлечь внимание за счет «жирной» халявы

Давайте посмотрим как изменилась конверсия во вторую покупку? Если наша гипотеза о том, что есть «халявщики», неверна, то эта конверсия не должна была уменьшиться

Интерпретация результатов

- Представим ситуацию:

Группа 1: даем 10% на первые две покупки

Группа 2: даем 20% на первую покупку

Группа 2 статзначимо выиграла. Какой вывод мы можем сделать?

Интерпретация результатов

- Представим ситуацию:

Было две группы, мы не получили статзначимости в результатах.

Но у нас есть уверенность, что продукт супер крутой, что мы сделали не так?

Интерпретация результатов

- Представим ситуацию:

Группа 1: отправляем эмейл письмо с предложением кредитки с 2 кликабельными картинками внутри письма

Группа 2: отправляем эмейл письмо с предложением кредитки с 1 кликабельной картинкой внутри письма

Группа 2 победила, хотя мы ожидали что выиграет группа 1 и все предпосылки показывали, что группа 1 будет более выигрышной. Но что-то пошло не так...

Оказалось, что для почтовиков gmail почта фильтрует письма как маркетинговые рассылки по количеству ссылок в письме и отправляет в отдельную папку, в то время как для других почтовиков фильтрации нет. И подсчет показал, что 40% всех почт это gmail. Таким образом получили узкое место, которое повлияло на результат

Интерпретация результатов

- Представим ситуацию:

Группа 1: отправляем пуш

Группа 2: отправляем пуш + эмейл

Группа 3: ничего не отправляем

Группа 1 выиграла группу 3 с $p_value = 0.00001$, группа 2 выиграла группу 3 с $p_value = 0.03$, группа 1 выиграла группу 2 с $p_value = 0.04$. Делаем вывод, что группа 1 выиграла

А точно ли она выиграла?

Интерпретация результатов

- Что в итоге надо делать после подведения результатов?
 1. Смотрим на наши прокси и контрольные метрики и как мы на них повлияли
 2. При отсутствии статзначимости в целевой метрике, смотрим на наличие статзначимости в прокси метриках (с некоторыми оговорками)
 3. При отсутствии статзначимости проверяем насколько релевантно был выбран таргет, ищем узкие места в тесте
 4. Не забываем про поправки на множественное тестирование
 5. Помним, что бизнес = деньги
 6. Помним, что АБ тест не только про выбор и подсчет статистического критерия, но и про бизнесовые и продуктовые показатели

Множественные сравнения

Простой АБ-тест проводит сравнение 2 групп.

А что, если их больше? Почему нельзя попарно сравнивать?

- Проведем тест с n сравнениями, критерий проверяем с уровнем значимости α
- Вероятность принятия для каждого из критериев $1 - \alpha$, вероятность принять все и ошибиться $1 - (1 - \alpha)^n$

Если просто сравнивать без поправок, то обычно допустимая вероятность ошибки в 5% разрастается до 19% при $n=4$

А при $n=14$ ваши результаты уже эквивалентны подбрасыванию монетки

Множественные сравнения. Как с этим быть

		Верна ли H_0 на самом деле?		
		Верна	Не верна	Итог
Принимаем ли мы H_0 (в результате теста)?	Принимается	$U = \text{Count}(\text{true negative})$	$T = \text{Count}(\text{false negative})$	A (accepted)
	Отвергается	$V = \text{Count}(\text{false positive})$	$S = \text{Count}(\text{true positive})$	D (declined)
	Итог	n (неизвестное)	N-n	N

Множественные сравнения. Как с этим быть?

Для оценки используются статистики, с помощью которых мы ограничим кол-во ошибок первого рода:

$FWER = P(V \geq 1)$ - Family-Wise Error Rate, вероятность хотя бы одной ошибки первого рода

$FDP = \begin{cases} \frac{V}{D}, D > 0 \\ 0, D = 0 \end{cases}$ - False Discovery Proportion, доля ошибок первого рода среди всех отклоненных гипотез

$FDR = E[FDP]$ - средняя доля ошибок первого рода

Обычно пользуемся оценками FWER

Множественные сравнения. Поправка Бонферрони

- Смысл поправки – проверять все гипотезы по критерию на уровне значимости $\frac{\alpha}{n}$
- В таком случае $FWER \leq \alpha$, доверительный интервал у каждой статистики длины $1 - \frac{\alpha}{n}$
- Это довольно грубая поправка, так как мощность критерия падает с увеличением n
- Для теста из 3-4 групп это обычно работает

Множественные сравнения для отчаявшихся. Поправка Холма-Бонферрони

Частичное решение проблемы с мощностью

Это нисходящий метод, то есть нужно отранжировать p-value:

$p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(n)}$, соответствуют гипотезам $H_{(1)}, H_{(2)}, \dots, H_{(n)}$

Теперь идем от 1 до n со счетчиком i :

$$\left\{ \begin{array}{l} \text{Если } p_{(i)} \geq \frac{\alpha}{n - i + 1}, \text{ то принимаем гипотезы } H_{(i)} \dots H_{(n)} \text{ и отвергаем все предыдущие, останавливаемся} \\ \text{Иначе, при } p_{(i)} < \frac{\alpha}{n - i + 1} \text{ отвергаем } H_{(1)} \dots H_{(i)} \text{ и увеличиваем } i \text{ на } 1 \end{array} \right.$$

С такой поправкой $FWER \leq \alpha$, однако мощность выше

Выводы

01

Проверяем группы на репрезентативность

Есть удобные одновыборочные критерии для этого и Stability Index

02

Проверяем гомогенность групп

Пользуемся двухвыборочными критериями и проверяем неключевые метрики.
+ Stability Index

03

Сравниваем тест и контроль

Применяем двухвыборочные критерии к ключевым метрикам

04

Проверяйте распределения на нормальность

Точно ли нужен слабый, но универсальный Манн-Уитни?

05

80% задач решаются параметрическими критериями

Критерии Фишера и Стьюдента удобнее в пользовании и мощнее

06

Не забудьте про множественные сравнения!

Если в вашем тесте более 4 групп, то внесите поправки!

07

Правильно интерпретируем результаты и делаем выводы



ТИНЬКОФФ

Всем спасибо!

